

# Rep-SliceMix-Net : segmentation cérébrale 2.5D compacte sur iSeg-2017

Clément Castiglione   Matis Codjia  
Simon Naulet   William Parker

5 septembre 2026

## Résumé

La segmentation du cerveau à six mois est difficile en raison du faible contraste entre matière grise et matière blanche pendant la phase isointense. Nous proposons Rep-SliceMix-Net, un réseau 2.5D qui combine cinq coupes et partage ses poids entre les plans axial, coronal et sagittal. Son encodeur alterne des convolutions spatiales et inter-coupes par canal, puis un décodeur 2D reconstruit la coupe centrale. Une reparamétrisation structurelle fusionne les branches utilisées pendant l’entraînement avant le déploiement. Le modèle final contient 543 380 paramètres déployés, soit environ 38 fois moins que la baseline nnU-Net 2D planifiée. Sur le fold étudié, composé de huit sujets d’entraînement et deux sujets de validation, il atteint des Dice de 0,95388 pour le liquide céphalo-rachidien, 0,91830 pour la matière grise et 0,89686 pour la matière blanche, soit une moyenne de 0,92302. La fusion tri-plan améliore cette moyenne de 0,89966 à 0,92302 face à l’inférence axiale du même modèle, sans ajouter de paramètres. Les résultats restent limités à un fold et devront être confirmés par validation croisée.

## 1 Introduction

iSeg-2017 porte sur la segmentation d’IRM cérébrales de nourrissons âgés de six mois en trois tissus : liquide céphalo-rachidien (CSF), matière grise (GM) et matière blanche (WM). À cet âge, l’intensité de la GM et de la WM se recouvre fortement sur les séquences T1 et T2. L’information locale est donc ambiguë et la position anatomique ainsi que le contexte spatial prennent une importance particulière [1].

Le projet vise simultanément une segmentation précise, en particulier pour la GM et la WM, un faible nombre de paramètres et une architecture identifiable. Une première baseline nnU-Net v2 2D fournit un point de comparaison robuste, mais utilise plus de 20 millions de paramètres. Un U-Net 2D compact donne une borne basse de complexité. Entre ces deux régimes, nous étudions un modèle 2.5D qui conserve la résolution d’une coupe entière tout en exploitant un voisinage court dans la troisième dimension.

Les contributions principales sont les suivantes :

- un encodeur 2.5D à mélange spatial et inter-coupes factorisé, associé à un décodeur 2D léger ;
- un seul jeu de poids pour les trois plans anatomiques, modulé par FiLM et complété par une agrégation apprise des coupes ;
- une étude contrôlée de la capacité, de la supervision profonde, de l’espacement des coupes, des canaux de position et du coût de l’inférence multi-plan.

## 2 Données et protocole

### 2.1 Dataset et séparation des sujets

Le dataset fournit dix sujets annotés et treize sujets de test sans annotation publique. Chaque sujet possède des volumes T1 et T2 co-enregistrés ainsi qu’une segmentation manuelle pour les

données d’entraînement. Les quatre classes sont le fond, le CSF, la GM et la WM. L’absence des annotations de test empêche le calcul local d’un score officiel.

Toutes les séparations sont effectuées par sujet. Le fold 0 utilisé dans cette étude contient les sujets 002 à 007, 009 et 010 pour l’entraînement, puis les sujets 001 et 008 pour la validation. Cette séparation est commune à Rep-SliceMix-Net, au U-Net compact et à nnU-Net. Elle exclut toute fuite entre des coupes issues d’un même volume.

## 2.2 Prétraitement

Les volumes sont orientés dans le repère canonique RAS et rééchantillonnés à 1 mm isotrope si nécessaire. L’isotropie permet de partager les poids entre les trois plans sans introduire de différence d’échelle. Un masque cérébral est calculé à partir des intensités finies et non nulles de T1 ou T2. Une fermeture morphologique, la conservation de la plus grande composante connexe et le remplissage des trous stabilisent ce masque. Les annotations ne sont utilisées ni pour le crop, ni pour la normalisation.

Une boîte englobante avec une marge de huit voxels réduit le fond inutile. Les dimensions sont complétées jusqu’au multiple de 16 suivant. Chaque modalité est normalisée par z-score, avec des statistiques calculées uniquement dans le masque cérébral. Trois canaux de coordonnées normalisées  $x$ ,  $y$  et  $z$  sont calculés sur le volume canonique complet avant le crop, puis découpés avec les images. Ils conservent ainsi un repère de position commun. Un sujet prétraité contient T1, T2, les trois coordonnées, le masque cérébral et, pour l’ensemble d’entraînement, le label.

## 2.3 Échantillonnage 2.5D et augmentations

Un élément d’entraînement est défini par un sujet, un plan, une coupe centrale  $z$  et un espacement  $d$ . Le sujet et le plan sont tirés uniformément. Les cinq indices sont  $[z - 2d, z - d, z, z + d, z + 2d]$ , avec clamp aux limites. La configuration de référence utilise  $d = 1$  dans 75 % des cas et  $d = 2$  dans 25 % des cas. Le centre appartient à une coupe contenant du cerveau avec une probabilité de 90 %, ce qui limite les exemples entièrement vides tout en conservant une part de fond. L’entrée a la forme  $[B, 6, 5, H, W]$  et la cible correspond uniquement à la coupe centrale.

Les flips, rotations jusqu’à  $15^\circ$  et changements d’échelle de 10 % sont appliqués de façon identique aux cinq coupes, aux six canaux et au label. Le gamma, le bruit gaussien et le champ de biais multiplicatif concernent seulement T1 et T2. Les coordonnées et le masque ne reçoivent aucune augmentation d’intensité.

## 2.4 Métriques

Le Dice d’une classe  $c$  est calculé sur le volume reconstruit :

$$\text{Dice}_c = \frac{2|P_c \cap G_c|}{|P_c| + |G_c|}. \quad (1)$$

Les Dice sont calculés séparément pour chaque sujet, puis moyennés sur les sujets et sur les trois classes de tissu. Le fond est exclu. La distance de Hausdorff au 95e percentile (HD95) et la distance moyenne de surface (ASD) complètent l’évaluation du modèle final.

# 3 Architecture proposée

## 3.1 Motivation du choix 2.5D

Le choix 2.5D repose sur le champ de vision disponible dans une coupe complète. Chaque prédiction observe la position globale du voxel dans un plan à pleine résolution, alors qu’un entraînement 3D par patchs limite ce contexte à la taille du patch. Les cinq coupes apportent une information locale dans la troisième dimension et les trois canaux de coordonnées explicitent la position dans le volume. Cette combinaison est adaptée à la phase isointense, où l’apparence locale seule sépare difficilement la GM de la WM.

Un U-Net 3D à blocs factorisés (2+1)D constituerait un concurrent direct et raisonnable en calcul. Cette comparaison n’a pas pu être exécutée dans le temps disponible. Les résultats présentés évaluent donc l’intérêt du 2.5D face aux baselines 2D, sans conclure à sa supériorité sur une architecture 3D compacte.

### 3.2 Vue d’ensemble

Rep-SliceMix-Net traite une coupe entière à sa résolution native. Cinq coupes voisines fournissent le contexte hors plan, sans recourir à des patchs 3D. Le réseau partage ses convolutions entre les orientations et reçoit l’identité du plan sous la forme d’un entier. Les largeurs sont [24, 48, 96, 192] et les profondeurs [2, 2, 2, 1].

TABLE 1 – Organisation de Rep-SliceMix-Net.  $S$  désigne le nombre de coupes encore présentes dans l’encodeur.

| Partie           | Sortie                    | Canaux         | Opération principale                            |
|------------------|---------------------------|----------------|-------------------------------------------------|
| Branche centrale | $H \times W$              | 16             | Conv2d $3 \times 3$ sur la coupe centrale       |
| Stem             | $5 \times H/2 \times W/2$ | 24             | Conv3d $1 \times 3 \times 3$                    |
| Stage 1          | $S = 5$                   | 24             | 2 RepSliceMix, FiLM, SlicePool                  |
| Transition 1     | $S = 3$                   | 48             | Conv3d $3 \times 1 \times 1$ , stride spatial 2 |
| Stage 2          | $S = 3$                   | 48             | 2 RepSliceMix, FiLM, SlicePool                  |
| Transition 2     | $S = 1$                   | 96             | Conv3d $3 \times 1 \times 1$ , stride spatial 2 |
| Stage 3          | $S = 1$                   | 96             | 2 RepSliceMix, FiLM, squeeze                    |
| Bottleneck       | $H/16 \times W/16$        | 192            | 1 bloc 2D                                       |
| Décodeur         | $H \times W$              | 96, 48, 24, 16 | Upsampling bilinéaire et skips 2D               |
| Tête             | $H \times W$              | 4              | Conv2d $1 \times 1$                             |

La branche centrale 2D travaille directement à pleine résolution et fournit le premier skip du décodeur. Elle préserve les contours fins, notamment ceux du CSF, sans multiplier ce calcul par les cinq coupes. Le stem principal réduit la résolution dans le plan. Les deux premières transitions réduisent ensuite la dimension des coupes de 5 à 3, puis de 3 à 1, grâce à des convolutions valides  $3 \times 1 \times 1$ . Après cette réduction, le bottleneck et le décodeur sont entièrement 2D.

### 3.3 Bloc RepSliceMix

Pour une entrée  $x \in \mathbb{R}^{B \times C \times S \times H \times W}$ , un bloc effectue successivement :

$$u = \text{GELU}(\text{RepDW}_{1 \times 3 \times 3}(x)), \quad (2)$$

$$v = \text{GELU}(\text{RepDW}_{3 \times 1 \times 1}(u)), \quad (3)$$

$$m = \text{Conv}_{1 \times 1 \times 1}^{2C \rightarrow C} \left( \text{GELU} \left( \text{Conv}_{1 \times 1 \times 1}^{C \rightarrow 2C}(v) \right) \right), \quad (4)$$

$$y = x + \lambda \odot \text{BN}(m). \quad (5)$$

La seconde ligne est omise lorsque  $S = 1$ . Le paramètre de couche  $\lambda$  est appris par canal et initialisé à  $10^{-2}$ .

La factorisation distingue les relations dans le plan et entre les coupes. Une convolution 3D dense  $3 \times 3 \times 3$  de  $C$  vers  $C$  contient approximativement  $27C^2$  poids. Les deux convolutions par canal utilisées ici en contiennent  $12C$ , auxquelles s’ajoutent environ  $4C^2$  poids pour le mélange de canaux. Les activations intermédiaires conservent deux transformations non linéaires successives et réduisent fortement le coût par rapport à un noyau 3D dense.

### 3.4 Partage tri-plan

Les mêmes poids convolutifs traitent les plans axial, coronal et sagittal. Une modulation FiLM [2] est appliquée à la fin de chaque stage :

$$\text{FiLM}(x, p) = \gamma_p \odot x + \beta_p, \quad (6)$$

où  $p$  est le plan et où  $\gamma_p, \beta_p \in \mathbb{R}^C$  proviennent d’un embedding appris. Les skips 3D sont ramenés en 2D par une somme pondérée des coupes. Les poids de cette opération, appelée SlicePool, dépendent du plan et du canal. Ce conditionnement permet de tenir compte des orientations anatomiques tout en conservant un seul encodeur.

À l’inférence, chaque plan produit un volume de probabilités dans son propre repère. Ces volumes sont réorientés dans le repère canonique puis moyennés avant l’argmax. La fusion tardive ne modifie pas le nombre de paramètres, mais son coût croît avec le nombre de vues.

### 3.5 Reparamétrisation pour le déploiement

Pendant l’entraînement, chaque RepDW additionne une branche avec le noyau principal, une branche  $1 \times 1$  et une branche identité. Chaque branche possède sa propre normalisation par batch. Suivant RepVGG [3] et Diverse Branch Block [4], les convolutions et leurs normalisations sont fusionnées algébriquement. Le noyau  $1 \times 1$  et le noyau identité sont centrés dans le noyau principal, puis les poids et biais des trois branches sont additionnés.

Cette transformation ramène chaque RepDW à une seule convolution par canal avec biais. Les convolutions spatiale et inter-coupes restent distinctes car un GELU les sépare. Un test unitaire compare les sorties avant et après fusion en mode évaluation et impose une erreur absolue maximale inférieure à  $10^{-4}$ . Le nombre de paramètres passe de 548 516 pendant l’entraînement à 543 380 au déploiement. La réduction, proche de 0,94 %, est modeste. L’intérêt principal est de retirer les branches auxiliaires du graphe d’inférence. En précision FP32, les poids déployés occupent environ 2,17 Mo, hors métadonnées du fichier.

## 4 Entraînement et inférence

La fonction de coût combine Dice différentiable, entropie croisée et terme de frontière :

$$\mathcal{L} = 0,6 \mathcal{L}_{Dice} + 0,3 \mathcal{L}_{CE} + 0,1 \mathcal{L}_{BoundaryCE}. \quad (7)$$

Le Dice est moyenné sur CSF, GM et WM. Le terme de frontière multiplie l’entropie croisée par 3 pour les pixels situés à moins de deux pixels d’une interface, et par 1 ailleurs. Il vise directement les interfaces GM/WM, peu contrastées sur les images.

TABLE 2 – Configuration de l’entraînement B0.

| Élément    | Valeur                                                           |
|------------|------------------------------------------------------------------|
| Optimiseur | AdamW, learning rate $3 \times 10^{-4}$ , weight decay $10^{-4}$ |
| Schedule   | warmup linéaire 5 %, puis décroissance cosinus                   |
| Durée      | 200 epochs, 250 itérations par epoch                             |
| Batch      | 16                                                               |
| Précision  | AMP FP16, gradient clipping à 1,0                                |
| EMA        | decay 0,999                                                      |
| Validation | axiale toutes les 5 epochs, tri-plan toutes les 10 epochs        |
| Sélection  | meilleur Dice volumique tri-plan avec les poids EMA              |

Les normalisations, biais, paramètres de couche et embeddings sont exclus du weight decay. Le run B0 a effectué 50 000 itérations sans arrêt anticipé. Son meilleur checkpoint est celui de l’epoch 200. Six workers persistants, l’optimiseur AdamW fusionné et une mise à jour EMA groupée réduisent le temps mesuré de 182,71 à 163,64 ms par itération, soit un gain de 11,7 % à loss et mémoire identiques. BF16 s’est montré 27 % plus lent sur la RTX 5070 Ti. `torch.compile` a été écarté en raison des recompilations associées aux formes variables. Le run complet B0 a duré environ 2,66 heures.

## 5 Expériences

### 5.1 Baselines

Le U-Net [5] compact utilise uniquement la coupe centrale. Il reçoit les mêmes six canaux, le même prétraitement, le même fold, la même fonction de coût et le même sampler de plans. Il contient 99 578 paramètres. Cette configuration permet une comparaison appariée à budget d’entraînement identique jusqu’à l’époch 90. Son run s’arrête à l’époch 94 ; il sert de baseline contrôlée et non de résultat à convergence garantie.

nnU-Net v2 [6] constitue la seconde baseline. Le planner a sélectionné un PlainConvUNet 2D à six niveaux, avec des patchs  $160 \times 128$ , un batch de 41 et 20 621 364 paramètres. Il utilise T1 et T2, son prétraitement automatique et le même partage de sujets pour le fold 0. Le run a été interrompu vers l’époch 667 après environ 200 epochs sans amélioration du meilleur EMA pseudo-Dice. Le meilleur checkpoint, enregistré à l’époch 443, possède un EMA pseudo-Dice de 0,90691. Ce plateau prolongé permet de considérer la baseline comme convergée pour cette expérience. Le pseudo-Dice nnU-Net est calculé en ligne sur les patchs de validation et ne suit pas exactement notre agrégation volumique tri-plan. Il est donc rapporté séparément.

### 5.2 Ablations

Les modifications sont testées séparément avec la même graine et le même horizon de scheduler. Les screenings à 30, 50 ou 100 epochs réduisent le coût des variantes défavorables tout en gardant les points de comparaison de B0.

TABLE 3 – Ablations d’architecture et d’échantillonnage sur le fold 0. Les paramètres correspondent au modèle déployé.

| Variante | Modification                                    | Paramètres | e30     | e50     | e100           |
|----------|-------------------------------------------------|------------|---------|---------|----------------|
| B0       | Référence, 75 % de $d = 1$                      | 543 380    | 0,90844 | 0,91537 | 0,92097        |
| B1       | Noyau reparamétrable $7 \times 7$ au bottleneck | 551 060    | 0,90834 | 0,91420 | –              |
| B2       | Supervision profonde                            | 543 380    | 0,89723 | –       | –              |
| B4       | Deux blocs au bottleneck                        | 693 908    | 0,89248 | 0,91428 | –              |
| B5       | $d = 1$ uniquement                              | 543 380    | 0,90732 | 0,91717 | <b>0,92242</b> |

B1 ne justifie pas ses paramètres supplémentaires. B2 dégrade le Dice moyen de 0,01121 à l’époch 30, principalement sur la WM. B4 ajoute 28 % de paramètres et reste légèrement sous B0 à l’époch 50. Ces variantes n’ont pas été prolongées. B5 améliore B0 de 0,00145 à l’époch 100, avec un gain sur les trois classes et les deux sujets. Cet écart demeure inférieur au seuil de 0,002 fixé pour conclure sur un seul fold. B5 reste donc une piste à confirmer sur un second fold plutôt qu’une nouvelle référence.

#### 5.2.1 Apport des canaux de position

Une ablation supplémentaire isole l’apport des trois coordonnées normalisées. Les variantes D0 et D0’ utilisent uniquement le plan axial et désactivent FiLM afin de ne pas confondre l’effet du repère spatial avec celui du conditionnement ou de la fusion tri-plan. D0 reçoit T1, T2, les coordonnées  $x$ ,  $y$ ,  $z$  et le masque cérébral. D0’ conserve T1, T2 et le masque, mais retire les trois coordonnées. Le split, la graine, le prétraitement, les augmentations, la fonction de coût et le calendrier d’apprentissage sont identiques.

TABLE 4 – Ablation des canaux de position à l’époch 35 sur le fold 0. La validation est volumique et axiale, sans FiLM.

| Variante          | Coordonnées | CSF      | GM       | WM       | Moyenne  |
|-------------------|-------------|----------|----------|----------|----------|
| D0                | incluses    | 0,93824  | 0,89709  | 0,87488  | 0,90341  |
| D0′               | exclues     | 0,93867  | 0,88643  | 0,83872  | 0,88794  |
| $\Delta$ D0 – D0′ |             | −0,00042 | +0,01067 | +0,03617 | +0,01547 |

Le gain apparaît sur les deux sujets de validation, avec +0,01480 pour iSeg\_001 et +0,01614 pour iSeg\_008. Il concerne principalement la GM et la WM, tandis que le CSF reste inchangé. Les modèles déployés contiennent respectivement 542 372 et 541 292 paramètres. Le surcoût des coordonnées est donc de 1 080 paramètres, soit environ 0,2 % de la taille du modèle.

Une erreur de précision FP16 dans le chemin de validation sur ROCm a invalidé les mesures D0 des epochs 5 à 30. Elle n’a pas affecté l’optimisation et a été corrigée avant la validation à l’époch 35. D0′ a été exécuté entièrement avec le chemin corrigé. L’époch 35 constitue ainsi le seul point apparié exploitable. Cette observation soutient la conservation du repère spatial, mais reste préliminaire. Les valeurs absolues de D0 et D0′ ne sont pas directement comparables à B0, évalué avec FiLM et la fusion tri-plan.

### 5.3 Choix du fold unique

Une validation croisée à cinq folds fournirait une estimation plus stable et des intervalles de variabilité entre sujets. Son coût d’entraînement est presque linéaire avec le nombre de folds. Quatre entraînements B0 supplémentaires représentent environ 10,7 heures, auxquels s’ajoutent les baselines et les ablations. Le budget total aurait alors dépassé 20 heures de calcul local.

Le fold 0 fixe les données, la graine et les epochs de comparaison afin de favoriser des décisions appariées rapides. Cette stratégie augmente le nombre d’hypothèses examinées dans le temps disponible. Elle expose toutefois les résultats à la variabilité des deux sujets de validation et à une adaptation progressive des décisions à ce fold. Une validation croisée complète reste la prochaine étape nécessaire pour estimer la généralisation.

## 6 Résultats

### 6.1 Résultat principal

Le meilleur checkpoint B0 se situe à la dernière validation, à l’époch 200. Les deux sujets obtiennent des Dice moyens de 0,92123 et 0,92481.

TABLE 5 – Résultats volumiques du modèle B0 sur le fold 0.

| Classe       | Dice $\uparrow$ | HD95 $\downarrow$ | ASD $\downarrow$ |
|--------------|-----------------|-------------------|------------------|
| CSF          | 0,95388         | 1,00 mm           | 0,1316 mm        |
| GM           | 0,91830         | 1,00 mm           | 0,3399 mm        |
| WM           | 0,89686         | 1,00 mm           | 0,3853 mm        |
| Moyenne Dice | <b>0,92302</b>  |                   |                  |

La GM atteint 0,91830 et la WM 0,89686. Les ASD restent inférieures à 0,4 mm pour chaque tissu. La progression de B0 ralentit après l’époch 100, mais passe encore de 0,92097 à 0,92302 entre les epochs 100 et 200.

TABLE 6 – Comparaison appariée à l’époch 90 sur le fold 0.

| Modèle           | Paramètres | CSF            | GM             | WM             | Moyenne        |
|------------------|------------|----------------|----------------|----------------|----------------|
| U-Net 2D compact | 99 578     | 0,93815        | 0,89393        | 0,86120        | 0,89776        |
| Rep-SliceMix B0  | 543 380    | <b>0,95241</b> | <b>0,91563</b> | <b>0,89303</b> | <b>0,92036</b> |

## 6.2 Comparaison aux baselines locales

Rep-SliceMix améliore la moyenne de 0,02260, dont 0,02170 sur la GM et 0,03183 sur la WM. Ce gain est important pour une application où la qualité des interfaces entre tissus conditionne directement les mesures produites à partir de la segmentation. Il motive un budget de capacité supérieur à celui du U-Net minimal.

Le facteur 5,46 entre les deux nombres de paramètres provient du budget très réduit de la baseline. En valeur absolue, Rep-SliceMix reste sous le million de paramètres avec 543 380 paramètres déployés, soit environ 2,17 Mo en FP32. L’augmentation de capacité reste donc compatible avec un déploiement léger et s’accompagne d’un gain marqué sur la GM et la WM. Ce compromis privilégie la qualité de segmentation tout en conservant un réseau compact.

Rep-SliceMix utilise seulement 2,6 % des paramètres du nnU-Net 2D planifié, soit un facteur de réduction proche de 38. Le meilleur pseudo-Dice EMA de nnU-Net, 0,90691, a été suivi d’environ 200 epochs sans amélioration. Cette baseline est considérée comme stabilisée. La différence de protocole métrique interdit de convertir l’écart avec 0,92302 en gain direct. Les deux résultats indiquent qu’un réseau sous le million de paramètres peut atteindre une précision locale du même ordre qu’une baseline auto-configurée beaucoup plus grande.

## 6.3 Coût de l’inférence multi-plan

TABLE 7 – Compromis entre nombre de vues, Dice et latence. Les temps sont indicatifs et mesurés sur une RTX 5070 Ti.

| Configuration                | Vues | Dice moyen     | Temps par volume |
|------------------------------|------|----------------|------------------|
| Axial, $d = 1$               | 1    | 0,89966        | 0,957 s          |
| Sagittal, $d = 1$            | 1    | 0,91389        | 0,651 s          |
| Coronal + sagittal, $d = 1$  | 2    | 0,92269        | 1,605 s          |
| Tri-plan, $d = 1$            | 3    | <b>0,92302</b> | 2,562 s          |
| Tri-plan, $d = 1$ et $d = 2$ | 6    | 0,92308        | 4,829 s          |

Le passage de l’axial seul au tri-plan apporte 0,02335 de Dice. Les plans coronal et sagittal réunis conservent presque tout ce gain, avec un écart de 0,00033 et une vue de moins. Ajouter les prédictions à  $d = 2$  double le nombre de vues pour un gain de 0,00007. Le tri-plan à  $d = 1$  reste la configuration de qualité de référence. Le couple coronal et sagittal constitue le mode efficace si la latence est prise en compte.

## 6.4 Analyse qualitative

La figure 1 montre une segmentation spatialement cohérente sur des coupes de morphologies différentes. Les structures principales sont préservées et les erreurs forment surtout des bandes minces aux interfaces de tissus. Cette observation est cohérente avec une HD95 de 1 mm et avec la difficulté du contraste GM/WM.

## 6.5 Repère fourni par le classement iSeg

Le Tableau 8 place le résultat local sur l’échelle des meilleurs résultats publiés sur le site iSeg. HUST-CBIB est la meilleure entrée actuellement affichée. MSL\_SKKU et LIVIA correspondent aux meilleures valeurs du classement initial de 2017 [7].




FIGURE 1 – Exemples de segmentation sur le sujet de validation iSeg\_001. Les colonnes montrent l'image T1, la vérité terrain, la prédiction, leur superposition et les erreurs. Les trois lignes correspondent à des positions axiales distinctes. Les erreurs se concentrent principalement sur les interfaces fines entre GM et WM.

TABLE 8 – Comparaison numérique avec le classement public iSeg. Les équipes officielles sont évaluées sur les 13 sujets de test cachés. B0 est évalué sur deux sujets locaux et ne possède donc pas de rang officiel.

| Méthode                     | WM           | GM           | CSF          | Moyenne simple |
|-----------------------------|--------------|--------------|--------------|----------------|
| HUST-CBIB, test officiel    | <b>0,906</b> | <b>0,925</b> | <b>0,960</b> | <b>0,93033</b> |
| MSL_SKKU, test officiel     | 0,901        | 0,919        | 0,958        | 0,92600        |
| LIVIA, test officiel        | 0,897        | 0,919        | 0,957        | 0,92433        |
| Rep-SliceMix B0, fold local | 0,89686      | 0,91830      | 0,95388      | 0,92302        |



La valeur numérique moyenne de B0 représente 99,2 % de celle de HUST-CBIB et 99,7 % de celle de MSL\_SKKU. Pour la GM, ces rapports atteignent respectivement 99,3 % et 99,9 %. Ils donnent un repère d'échelle, sans mesurer une fraction de performance conservée : les cohortes et le protocole de sélection diffèrent. Une comparaison valide avec le classement demanderait les annotations des sujets 11 à 23, qui ne sont pas disponibles dans les données fournies. Le classement ne fournit pas le nombre de paramètres des méthodes, ce qui empêche une comparaison quantitative de leur compacité.

## 7 Discussion

Les résultats appariés soutiennent l'utilité du contexte 2.5D. Face au U-Net compact, les gains les plus élevés concernent la WM et la GM, les deux classes pour lesquelles le contraste local est le moins informatif. La différence entre l'axial seul et les vues coronal et sagittal confirme également que le contexte anatomique dépend de l'orientation. Le partage des poids permet d'exploiter ces vues sans tripler la taille du réseau. L'ablation D0/D0' indique en outre que les coordonnées explicites améliorent surtout la GM et la WM. Le contexte visuel et le repère spatial apportent ainsi des informations complémentaires dans le protocole étudié.

La factorisation des convolutions explique en grande partie la compacité du modèle. Le mélange inter-coupes est effectué seulement aux résolutions où plusieurs coupes sont encore présentes. Les couches profondes et le décodeur restent 2D. Cette organisation aboutit à 543 380 paramètres déployés et à une inférence tri-plan mesurée autour de 2,6 secondes par volume. Lorsque le coût est prioritaire, deux vues donnent un Dice presque identique autour de 1,6 seconde.

La reparamétrisation apporte peu de réduction de paramètres et son gain de latence est marginal sur ce réseau. Elle garantit toutefois un graphe déployé plus simple tout en autorisant plusieurs branches normalisées pendant l'entraînement. Les ablations indiquent que l'augmentation du noyau ou de la profondeur du bottleneck n'améliore pas la trajectoire de B0. La capacité brute du bottleneck ne semble donc pas constituer la limite principale dans le régime étudié. La supervision profonde testée pénalise nettement la WM, probablement parce que les sorties basse résolution représentent mal ses interfaces fines.

L'étude possède trois limites principales. Premièrement, les résultats de Rep-SliceMix et du U-Net compact proviennent d'un seul fold. Deuxièmement, plusieurs choix ont été effectués à partir des mêmes deux sujets, ce qui peut favoriser le fold 0. L'ablation des coordonnées ne dispose par ailleurs que d'un point apparié valide. Troisièmement, aucun Dice local n'est disponible sur le test officiel. Les écarts inférieurs à 0,002, comme celui de B5 ou des variantes TTA à six vues, restent donc indécis. Une validation croisée à cinq folds fournirait l'évaluation finale appropriée. Un modèle destiné à la livraison pourrait ensuite être réentraîné sur les dix sujets annotés.

## 8 Conclusion

Rep-SliceMix-Net atteint un Dice moyen de 0,92302 sur le fold étudié, avec 0,91830 sur la GM et 0,89686 sur la WM pour 543 380 paramètres déployés. La fusion tri-plan apporte 0,02335 face à l'inférence axiale, sans augmenter la taille du réseau. Le modèle reste sous le million de paramètres et utilise environ 2,6 % des paramètres de la baseline nnU-Net 2D planifiée. Les ablations ont conduit à conserver une architecture simple : un seul bottleneck, aucune supervision profonde, les canaux de position et une inférence tri-plan à  $d = 1$ . Le résultat se situe numériquement près des meilleures valeurs du classement iSeg, mais sa portée demeure locale en l'absence d'une validation croisée complète et des annotations du jeu de test.

## Références

- [1] L. Wang et al., "Benchmark on Automatic 6-month-old Infant Brain Segmentation Algorithms : The iSeg-2017 Challenge," *IEEE Transactions on Medical Imaging*, vol. 38, no. 9, pp. 2219–2230,

- 2019, [doi:10.1109/TMI.2019.2901712](https://doi.org/10.1109/TMI.2019.2901712).
- [2] E. Perez, F. Strub, H. de Vries, V. Dumoulin et A. Courville, “FiLM : Visual Reasoning with a General Conditioning Layer,” *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, pp. 3942–3951, 2018, [doi:10.1609/aaai.v32i1.11671](https://doi.org/10.1609/aaai.v32i1.11671).
  - [3] X. Ding, X. Zhang, N. Ma, J. Han, G. Ding et J. Sun, “RepVGG : Making VGG-Style ConvNets Great Again,” *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 13733–13742, 2021, [CVF Open Access](#).
  - [4] X. Ding, X. Zhang, J. Han et G. Ding, “Diverse Branch Block : Building a Convolution as an Inception-Like Unit,” *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 10886–10895, 2021, [CVF Open Access](#).
  - [5] O. Ronneberger, P. Fischer et T. Brox, “U-Net : Convolutional Networks for Biomedical Image Segmentation,” dans *Medical Image Computing and Computer-Assisted Intervention*, Lecture Notes in Computer Science, vol. 9351, pp. 234–241, 2015, [doi:10.1007/978-3-319-24574-4\\_28](https://doi.org/10.1007/978-3-319-24574-4_28).
  - [6] F. Isensee, P. F. Jaeger, S. A. A. Kohl, J. Petersen et K. H. Maier-Hein, “nnU-Net : a self-configuring method for deep learning-based biomedical image segmentation,” *Nature Methods*, vol. 18, pp. 203–211, 2021, [doi:10.1038/s41592-020-01008-z](https://doi.org/10.1038/s41592-020-01008-z).
  - [7] iSeg-2017, “Evaluation & Results,” [site officiel iSeg-2017](#), consulté le 5 septembre 2026.